

電信客戶流失預測系統

Customer Churn Prediction System

Group Members: 陸竑宇(411221425)、劉家均 (411221426)

Project Motivation & Objective

獲客 vs. 留客

在電信業中，獲取新客戶的成本 (CAC) 通常是留住既有客戶成本的 **5 到 25 倍**。

- ✓ 主動預測流失：在客戶流失前進行干預。
- ✓ 數據驅動決策：將直覺轉化為精確預測模型。
- ✓ 提升長期獲利：保留高價值客戶的終身價值。

建立一個能主動偵測潛在流失客戶的預測模型，協助客服進行預防性留存。

| Project Motivation & Objective

> 75%

目標 Recall 基準值

為什麼 Recall 至關重要？

模型寧可「錯發」挽留折扣予不流失客戶，
也不能「漏抓」即將流失的客戶。

偽陽性 (False Positive): 僅損失少許行銷折扣。

偽陰性 (False Negative): 徹底流失客戶的終身價值。

Dataset Description

Data Source: Kaggle *Telco Customer Churn*

數據規模 (Scale):

- 總樣本數 (Instances): 7,043 筆真實客戶數據
- 特徵維度 (Attributes): 21 個原始特徵欄位 (包含 1 個目標標籤)
- 資料格式 (Format): 結構化 CSV 表格數據

類別標籤與分佈 (Class Label & Distribution):

- 目標欄位: Churn (是否已退租流失: Yes / No)
- 分佈不平衡:
 - 未流失 (No): 5,174 筆 (73.47%)
 - 已流失 (Yes): 1,869 筆 (26.53%)

流失群體為少數類 需要進行類別不平衡處理

Data Preprocessing

基礎清洗

TotalCharges（總費用）
轉數值，填補空白值為 0，剔除
customerID 等無意義特徵。

特徵編碼 (Encoding)

二值特徵採用 Label Encoding
多分類特徵採用 One-Hot
Encoding 以利模型理解。

標準化縮放(Scaling)

對連續數值特徵進行 Standard
Scaling，加速線性模型（如
LR）的收斂速度。

計費比例 (ChargesRatio)



反映客戶的月費負擔，計算公式為：

$$\text{ChargesRatio} = \frac{\text{MonthlyCharges}}{\text{TotalCharges}}$$

高危險交互特徵

IsNewCustomer: 定義為入網 ≤ 12 個月。

MonthToMonth_NewCustomer: 標記「按月付款」且
「入網 ≤ 12 個月」的極高風險群體。



Model Construction

Logistic Regression

- L2 正規化 (Ridge)
- 正規化強度 $C = 1.0$
- `class_weight='balanced'`

Random Forest

- Bootstrap 採樣
- 節點分裂時隨機抽取 $\sqrt{D}$ 個特徵進行最佳分裂點搜尋

XGBoost

- `n_estimators=50`
- `max_depth=3`
- `learning_rate = 0.01`

Methodology

1. 類別不平衡處理方法

- 方法一: 演算法底層加權 —— 損失函數調整 (Weighted Loss Function)

- **Logistic Regression (Weighted)**: 在損失函數(加權交叉熵)中加大對少數類(流失)預測錯誤的懲罰。

- 類別權重計算法: $w_1 = \frac{N_{\text{samples}}}{2 \times N_{\text{churn}}} \approx 1.88$ (流失類), $w_0 = \frac{N_{\text{samples}}}{2 \times N_{\text{non-churn}}} \approx 0.68$ (非流失類)。這使得流失類的權重是正常類的 **2.76 倍**。

- **XGBoost (Weighted)**: 使用 `scale_pos_weight = 2.76` 提升少數類樣本在梯度迭代時的權重。

```
27 # Initialize optimized models
28 scale_pos_weight = (len(y_train) - sum(y_train)) / sum(y_train)
29 models = {
30     'Logistic Regression (SMOTE)': LogisticRegression(max_iter=1000, random_state=42),
31     'Logistic Regression (Weighted)': LogisticRegression(max_iter=1000, class_weight='balanced', random_state=42),
32     'Random Forest (SMOTE)': RandomForestClassifier(n_estimators=100, random_state=42),
33     'Random Forest (Weighted)': RandomForestClassifier(n_estimators=100, class_weight='balanced', random_state=42),
34     'XGBoost (Weighted)': XGBClassifier(
35         scale_pos_weight=scale_pos_weight,
36         learning_rate=0.01,
37         max_depth=3,
38         n_estimators=50,
39         subsample=1.0,
40         eval_metric='logloss',
41         random_state=42
42     )
43 }
```


Methodology

- 方法二: 特徵空間過採樣 — SMOTE 演算法

- 原理: *Synthetic Minority Over-sampling Technique* (合成少數類過採樣)。
- 步驟: 鎖定流失客戶 x_i , 在特徵空間中尋找其 5 個近鄰的流失樣本 x_{nn} , 進行隨機線性插值合成新的樣本:

$$x_{\text{new}} = x_i + \lambda(x_{nn} - x_i), \quad \lambda \in [0, 1]$$

- 效果: 在不簡單重複舊樣本的情況下, 將訓練集流失與非流失樣本的比例平衡至 1:1, 避免模型偏袒多數類。

```
23 # 1. SMOTE (Oversampling the minority class)
24 smote = SMOTE(random_state=42)
25 X_train_smote, y_train_smote = smote.fit_resample(X_train, y_train)
```

Methodology

3. 決策邊界調優 (Decision Boundary / Threshold Optimization)

模型最終輸出的是流失的機率 $P(y_i=1|x_i)$ 。在商業實務上，為滿足 Recall > 75% 的強烈需求，我們優化了最終的決策閾值 τ ：

$$\hat{y}_i = \begin{cases} 1, & \text{if } P(y_i = 1|x_i) \geq 0.45 \\ 0, & \text{otherwise} \end{cases}$$

- 將決策閾值從預設的 0.50 調降至 0.45，這是在強大的模型本質實力 (AUC = 0.8488) 基礎上，最能將流失召回率最大化且維持精準率平衡的決策配置。

```
47 # Decision boundary threshold for optimized models
48 THRESHOLD = 0.45
```

```
61 # Predictions (using custom decision threshold)
62 y_prob = model.predict_proba(X_test)[: , 1]
63 y_pred = (y_prob >= THRESHOLD).astype(int)
```


Performance Evaluation & Model Comparison

Model	Accuracy	Precision	Recall	F1-Score	AUC-ROC	☐標達成 (>75%)
Logistic Regression (Weighted)	72.46%	48.89%	82.62%	61.43%	0.8488	達成
Logistic Regression (SMOTE)	73.03%	49.46%	72.99%	58.96%	0.8252	未達成
XGBoost (Weighted)	62.24%	40.81%	93.85%	56.89%	0.8274	達成(但準確率偏低)
Random Forest (SMOTE)	73.95%	50.69%	68.45%	58.25%	0.8155	未達成
Logistic Regression	80.48%	66.67%	52.94%	59.02%	0.8490	未達成

Conclusion :

雖然 XGBoost (Weighted) 的召回率達到極高的 93.85%，但其準確率下降至 62.24%，Precision 僅 40.81%（誤報率高達 60%），在商業實務上會造成過多的成本浪費。

因此本專案最終選擇 邏輯斯迴歸 Logistic Regression (Weighted, 閾值 0.45)。它成功實現了 82.62% 的召回率，同時將準確率維持在 72.46%，且具備最優的整體分類能力（AUC = 0.8488）。









Performance Evaluation & Model Comparison

Baseline


Model	Accuracy	Precision	Recall	F1-Score	AUC
Logistic Regression	0.8048261178140526	0.6666666666666666	0.5294117647058824	0.5901639344262295	0.8490066909504249
Random Forest	0.7877927608232789	0.6334519572953736	0.47593582887700536	0.5435114503816794	0.8251259397039448
XGBoost	0.7764371894960965	0.5896656534954408	0.5187165775401069	0.5519203413940256	0.822379808313312

Optimized model


Model	Accuracy	Precision	Recall	F1-Score	AUC
Logistic Regression (SMOTE)	0.730305180979418	0.4945652173913043	0.7299465240641712	0.5896328293736501	0.8251750238962516
Logistic Regression (Weighted)	0.7246273953158269	0.4889240506329114	0.8262032085561497	0.614314115308151	0.8487948539099435
Random Forest (SMOTE)	0.7395315826827538	0.5069306930693069	0.6844919786096256	0.5824800910125142	0.8154886460513059
Random Forest (Weighted)	0.78708303761533	0.6081871345029239	0.5561497326203209	0.5810055865921788	0.8248611434033429
XGBoost (Weighted)	0.6224272533711852	0.40813953488372096	0.9385026737967914	0.5688816855753647	0.8273760624144256



Confusion Matrix - XGBoost (Weighted)
(Threshold: 0.45)



Confusion Matrix - XGBoost



Final Result / Demo

客戶特徵資料輸入

1. 客戶基本資料

性別	是否為年長者 (Senior Citizen)
女性	否

是否有配偶 (Partner)	是否有撫養家屬 (Dependents)
無	無

2. 電信服務配置

電話服務 (Phone Service)	多條電話線 (Multiple Lines)
有	無

網路服務 (Internet Service)	網路安全防護 (Online Security)
光纖 (Fiber Optic)	無

雲端備份服務 (Online Backup)	設備保險 (Device Protection)
無	無

技術支援服務 (Tech Support)	影音電視串流 (Streaming TV)
無	無

電影串流服務 (Streaming Movies)
無

← 資料輸入：整合客戶基本資料、服務配置與合約財務數據。



● 流失機率高 (建議啟動挽留方案)

決策警報閾值 0.45 (45.0%)

計費強度比 (Charges Ratio) 0.1000

客戶生命週期區間 入網 12 個月 高危險期

交互風險狀態 雙重高流失風險

評估建議：
透過優化後的模型即時運算流失機率。當機率高於決策閾值 (0.45) 時系統會自動觸發「挽留方案」建議。

電信客戶流失預測與預警演示系統

基於機器學習優化演算法與進階特徵工程，即時評估訂閱戶流失風險

特徵工程 V2

分類閾值：0.45

召回率 (Recall)：82.62%

加權邏輯斯迴歸

客戶特徵資料輸入

1. 客戶基本資料

性別	是否為年長者 (Senior Citizen)
女性	否
是否有配偶 (Partner)	是否有撫養家屬 (Dependents)
無	無

2. 電信服務配置

電話服務 (Phone Service)	多條電話線 (Multiple Lines)
有	無
網路服務 (Internet Service)	網路安全防護 (Online Security)
光纖 (Fiber Optic)	無
雲端備份服務 (Online Backup)	設備保險 (Device Protection)
無	無
技術支援服務 (Tech Support)	影音電視串流 (Streaming TV)
無	無

電影串流服務 (Streaming Movies)

無

3. 合約及財務資料

合約類型 (Contract Type)	無紙化電子帳單 (Paperless Billing)
兩年期合約 (Two year)	是
付款方式 (Payment Method)	入網在職月數 (Tenure in Months)
電子支票 (Electronic Check)	20
每月資費 (Monthly Charges, USD)	累積總資費 (Total Charges, USD)
79.85	798.50

評估流失風險

風險預估結果



客戶狀態穩定

決策警報閾值	0.45 (45.0%)
計費強度比 (Charges Ratio)	0.1000
客戶生命週期區間	在職 20 個月 成熟期
交互風險狀態	狀態良好

電信客戶流失預測與預警演示系統

基於機器學習優化演算法與進階特徵工程，即時評估訂閱戶流失風險

特徵工程 V2

分類閾值：0.45

召回率 (Recall)：82.62%

加權邏輯斯迴歸

客戶特徵資料輸入

1. 客戶基本資料

性別	是否為年長者 (Senior Citizen)
女性	否
是否有配偶 (Partner)	是否有撫養家屬 (Dependents)
無	無

2. 電信服務配置

電話服務 (Phone Service)	多條電話線 (Multiple Lines)
有	無
網路服務 (Internet Service)	網路安全防護 (Online Security)
光纖 (Fiber Optic)	無
雲端備份服務 (Online Backup)	設備保險 (Device Protection)
無	無
技術支援服務 (Tech Support)	影音電視串流 (Streaming TV)
無	無

電影串流服務 (Streaming Movies)

無

3. 合約及財務資料

合約類型 (Contract Type)	無紙化電子帳單 (Paperless Billing)
按月付款 (Month-to-month)	是
付款方式 (Payment Method)	入網在職月數 (Tenure in Months)
電子支票 (Electronic Check)	20
每月資費 (Monthly Charges, USD)	累積總資費 (Total Charges, USD)
79.85	798.50

評估流失風險

風險預估結果



流失機率高 (建議啟動挽留方案)

決策警報閾值	0.45 (45.0%)
計費強度比 (Charges Ratio)	0.1000
客戶生命週期區間	在職 20 個月 成熟期
交互風險狀態	狀態良好

Division of Work

陸竑宇 (411221425):

負責 **數據工程與系統整合**，主導特徵工程邏輯設計 (ChargesRatio 等關鍵指標) 以及 Demo 預測網頁開發。

劉家均 (411221426):

負責 **模型建構與優化分析**，主導模型訓練架構 (SMOTE/Weighted Loss 實作) 及超參數調校與決策邊界優化。

協同成果: 全體成員共同完成專案報告撰寫、數據分析洞察(EDA) 以及實驗結果視覺化呈現。

THANKS!!!